MACHINE LEARNING OPERATIONS

Dataset_version

UNLIMITED

Presented by Asst. Prof. Dr. Tuchsanai Ploysuwan

1. บทนำ: ความสำคัญของ Dataset Versioning

1.1 ปัญหาที่พบบ่อยในการจัดการข้อมูล ML

ในโปรเจกต์ Machine Learning ทั่วไป ทีมมักประสบปัญหาเหล่านี้:

```
❌ "Model ทำงานได้ดีเมื่อวานนี้ แต่วันนี้ Accuracy ตก ไม่รู้ว่าเปลี่ยนอะไรไป"
❌ "ใช้ Data ชุดไหนในการ Train Model version ที่ deploy อยู่?"
❌ "ใครแก้ไข Dataset? เมื่อไหร่? แก้อะไร?"
❌ "ต้องการกลับไปใช้ Data version เดิม แต่ไม่มี backup"
```

1.2 Dataset Versioning คืออะไร?

Dataset Versioning คือกระบวนการติดตามและจัดการการเปลี่ยนแปลงของชุดข้อมูลอย่างเป็นระบบ คล้ายกับที่ Git ทำกับ Source Code

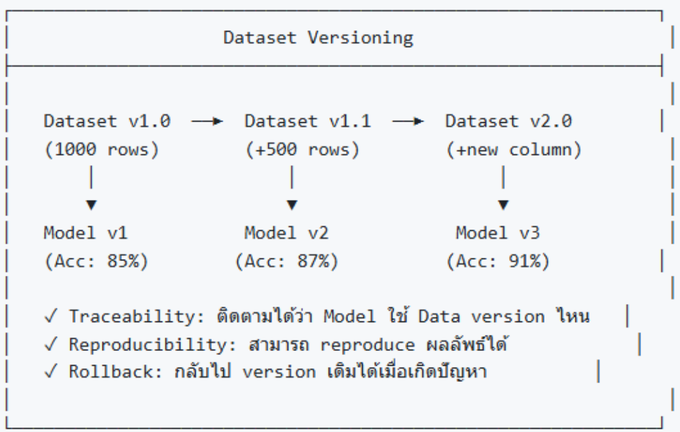

1.3 ทำไมต้องใช้ MLflow สำหรับ Dataset Tracking?

คุณสมบัติ	ประโยชน์
Centralized Tracking	เก็บข้อมูลทุกอย่างไว้ที่เดียว
Metadata Logging	บันทึก schema, statistics, hash
Artifact Storage	เก็บ Dataset files พร้อม versioning
UI Dashboard	ดูและเปรียบเทียบ versions ได้ง่าย
API Access	เข้าถึงข้อมูลผ่าน Python API

MLflow Components สำหรับ Dataset Tracking

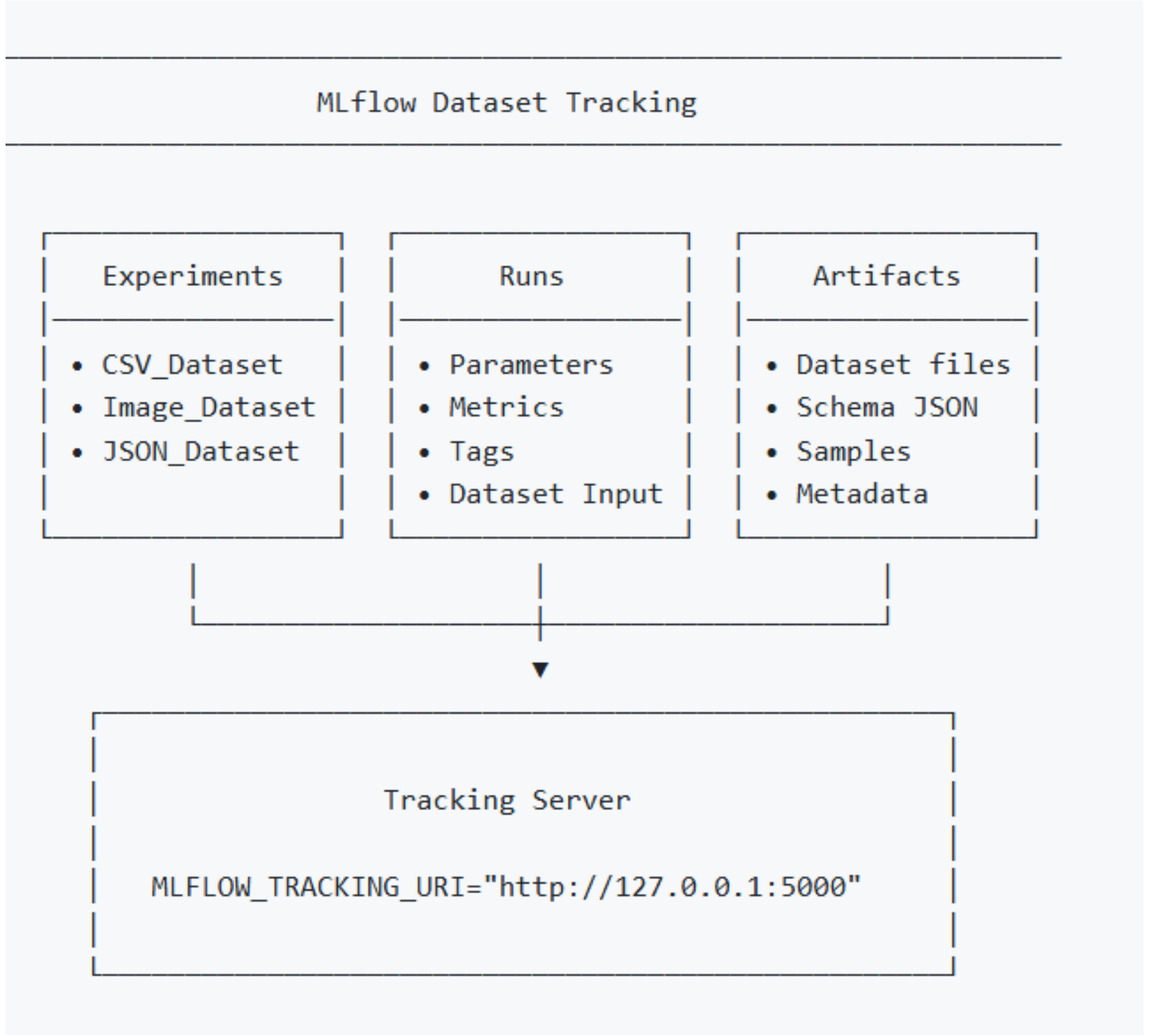

Dataset Versioning for Csv files

Data Lineage คือการติดตามที่มาและการเปลี่ยนแปลงของข้อมูลตลอด Pipeline

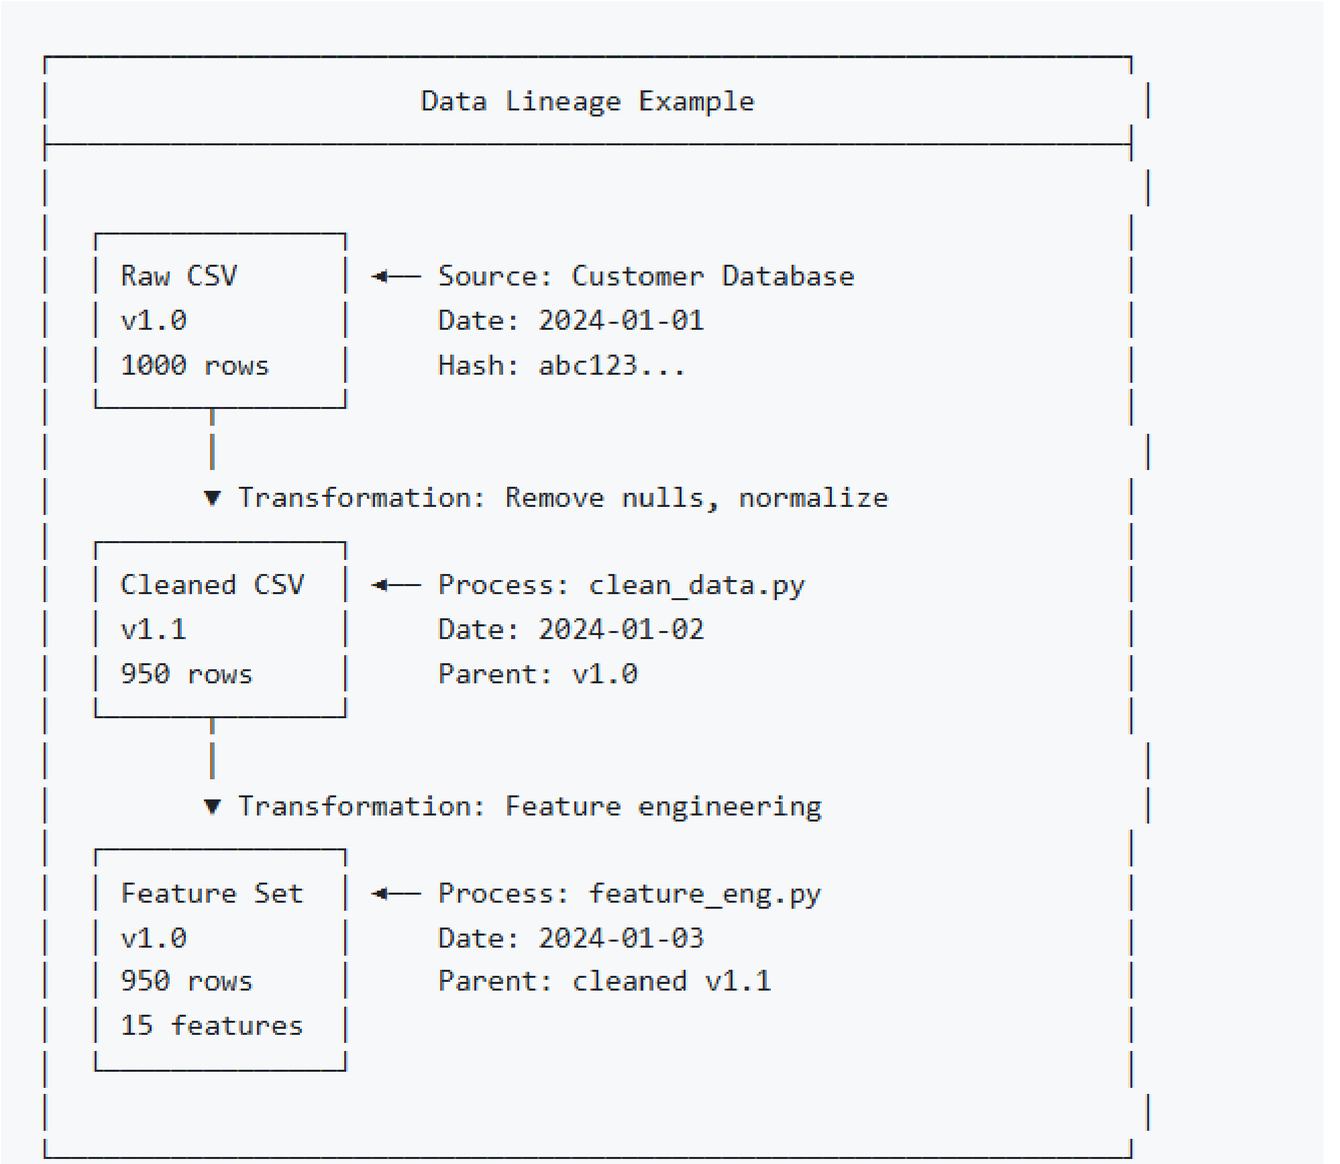

2.3 Dataset Versioning Strategies

การเลือก Versioning Strategy ที่เหมาะสมเป็นสิ่งสำคัญในการจัดการ Dataset ให้มีประสิทธิภาพ แต่ละ Strategy มีข้อดีและข้อเสียที่แตกต่างกัน ขึ้นอยู่กับลักษณะของโปรเจกต์และทีม

Strategy 1: Semantic Versioning (MAJOR.MINOR.PATCH)

Semantic Versioning ใช้หลักการเดียวกับ Software Versioning ที่เป็นที่นิยม โดยแบ่งเลข version เป็น 3 ส่วน

```
# Version Number Meaning:
# MAJOR: Breaking changes (schema change, column removal)
# MINOR: Backward compatible additions (new rows, new columns)
# PATCH: Bug fixes (data corrections)

version_examples = {
    "1.0.0": "Initial dataset",
    "1.1.0": "Added 500 new samples",        # Minor: more data
    "1.1.1": "Fixed typos in labels",        # Patch: corrections
    "2.0.0": "Added 'region' column",        # Major: schema change
}
```

เมื่อไหร่ควรใช้:

- เมื่อต้องการสื่อสารลักษณะการเปลี่ยนแปลงให้ทีมเข้าใจ
- เมื่อมี downstream dependencies ที่ต้องรู้ว่า data เปลี่ยนแปลงอย่างไร
- เหมาะกับ production datasets ที่มี consumers หลายคน

Strategy 2: Date-based Versioning

Date-based Versioning เหมาะกับ datasets ที่มีการ update เป็นประจำ เช่น daily snapshots หรือ monthly reports

```
# Format: YYYY-MM-DD or YYYYMMDD
version_examples = {
    "2024-01-01": "January snapshot",
    "2024-02-01": "February snapshot",
    "2024-02-15": "Mid-month update",
}
```

เมื่อไหร่ควรใช้:

- Datasets ที่ update เป็น schedule (daily, weekly, monthly)
- Time-series data หรือ snapshot data
- เมื่อ "เวลา" เป็นข้อมูลที่สำคัญในการ track

Strategy 3: Hash-based Versioning

Hash-based Versioning ใช้ Content Hash เป็น Version Identifier **ซึ่งเป็นวิธีที่ อัตโนมัติและแม่นยำที่สุด** เนื่องจาก version จะเปลี่ยนก็ต่อเมื่อเนื้อหาของไฟล์เปลี่ยนจริงๆ เท่านั้น

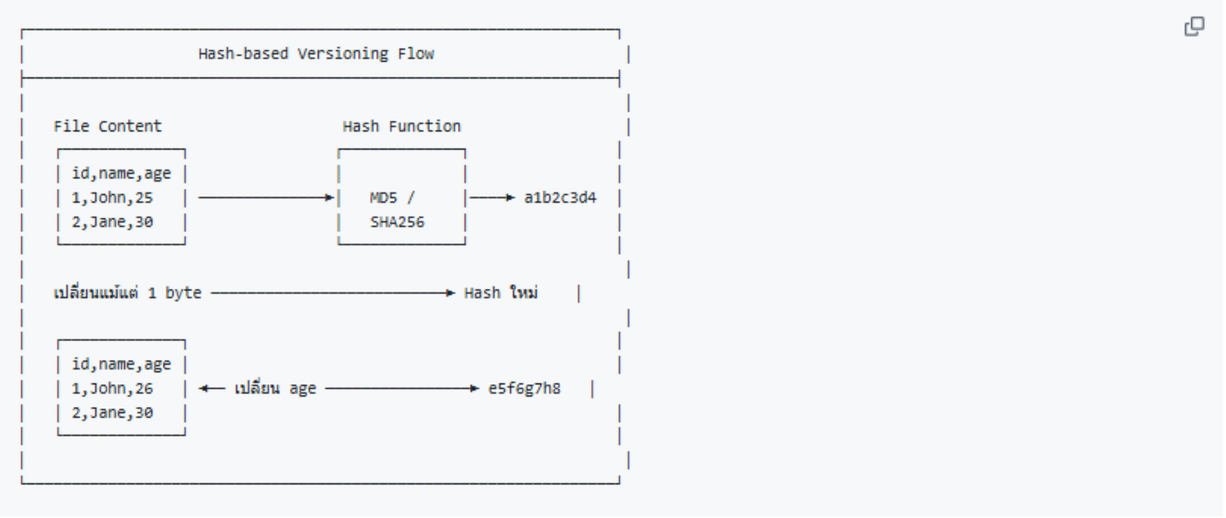

ข้อดีของ Hash-based Versioning:

ข้อดี	คำอธิบาย
Automatic	ไม่ต้อง manual update version number
Unique	แต่ละ content มี hash เฉพาะตัว
Integrity Check	ตรวจสอบความถูกต้องของไฟล์ได้
Deduplication	ตรวจจับ duplicate datasets ได้
Reproducibility	มั่นใจได้ว่าใช้ data ชุดเดียวกัน

ข้อดี	คำอธิบาย
Automatic	ไม่ต้อง manual update version number
Unique	แต่ละ content มี hash เฉพาะตัว
Integrity Check	ตรวจสอบความถูกต้องของไฟล์ได้
Deduplication	ตรวจจับ duplicate datasets ได้
Reproducibility	มั่นใจได้ว่าใช้ data ชุดเดียวกัน


```python
import hashlib
import pandas as pd
import os

def get_dataset_version(filepath):
    """
    สร้าง version จาก file content hash

    Args:
        filepath: path ไปยังไฟล์ dataset

    Returns:
        str: 8-character hash string เป็น version identifier
    """
    hash_md5 = hashlib.md5()
    with open(filepath, "rb") as f:
        for chunk in iter(lambda: f.read(4096), b""):
            hash_md5.update(chunk)
    return hash_md5.hexdigest()[:8]  # ใช้ 8 characters แรก

# ตัวอย่างการใช้งาน
version = get_dataset_version("data/customers.csv")
print(f"Dataset Version: {version}")  # ผลลัพธ์: "a1b2c3d4"
```

4.2 Track CSV Dataset with MLflow

Now let's create an MLflow experiment and log our CSV datasets with proper versioning and metadata.

[5]:
```python
def calculate_file_hash(filepath):
    """Calculate MD5 hash of a file for versioning."""
    hash_md5 = hashlib.md5()
    with open(filepath, "rb") as f:
        for chunk in iter(lambda: f.read(4096), b""):
            hash_md5.update(chunk)
    return hash_md5.hexdigest()

def get_dataset_stats(df):
    """Generate statistics for a DataFrame."""
    stats = {
        "num_rows": len(df),
        "num_columns": len(df.columns),
        "columns": list(df.columns),
        "dtypes": {col: str(dtype) for col, dtype in df.dtypes.items()},
        "missing_values": df.isnull().sum().to_dict(),
        "memory_usage_mb": df.memory_usage(deep=True).sum() / (1024 * 1024)
    }

    # Add numeric column statistics
    numeric_cols = df.select_dtypes(include=[np.number]).columns
    if len(numeric_cols) > 0:
        stats["numeric_stats"] = df[numeric_cols].describe().to_dict()

    return stats

print("✅ Helper functions created!")
```

```
✅ Helper functions created!
```

[6]:
```python
# Create experiment for CSV datasets
EXPERIMENT_NAME_CSV = "CSV_Dataset_Versioning_Lab"

# Set or create experiment
mlflow.set_experiment(EXPERIMENT_NAME_CSV)
experiment = mlflow.get_experiment_by_name(EXPERIMENT_NAME_CSV)
print(f"📁 Experiment: {EXPERIMENT_NAME_CSV}")
print(f"   Experiment ID: {experiment.experiment_id}")
```

```
2026/02/02 08:46:47 INFO mlflow.tracking.fluent: Experiment with name 'CSV_Dataset_Versioning_Lab' does not exist. Creating a n
ew experiment.
📁 Experiment: CSV_Dataset_Versioning_Lab
   Experiment ID: 1
```

Version 1

```python
# Log CSV Dataset Version 1
print("🔄 Logging CSV Dataset Version 1...")

with mlflow.start_run(run_name="customer_dataset_v1") as run:
    # Load the dataset for MLflow
    df = pd.read_csv(csv_path_v1)

    # Create MLflow dataset
    dataset = mlflow.data.from_pandas(
        df,
        source=csv_path_v1,
        name="customer_churn_dataset",
        targets="churn"
    )

    # Log the dataset
    mlflow.log_input(dataset, context="training")

    # Log dataset metadata as parameters
    mlflow.log_param("dataset_version", "1.0.0")
    mlflow.log_param("dataset_name", "customer_churn")
    mlflow.log_param("data_source", "synthetic")
    mlflow.log_param("creation_date", datetime.now().isoformat())

    # Log dataset statistics as metrics
    stats = get_dataset_stats(df)
    mlflow.log_metric("num_rows", stats["num_rows"])
    mlflow.log_metric("num_columns", stats["num_columns"])
    mlflow.log_metric("memory_mb", stats["memory_usage_mb"])
    mlflow.log_metric("missing_total", sum(stats["missing_values"].values()))
    mlflow.log_metric("churn_rate", df['churn'].mean())

    # Log the actual CSV file as artifact
    mlflow.log_artifact(csv_path_v1, artifact_path="datasets")

    # Log schema information
    schema_info = {
        "columns": stats["columns"],
        "dtypes": stats["dtypes"],
        "version": "1.0.0"
    }
    schema_path = os.path.join(CSV_DIR, "schema_v1.json")
    with open(schema_path, 'w') as f:
        json.dump(schema_info, f, indent=2)
    mlflow.log_artifact(schema_path, artifact_path="schema")

    # Log file hash for integrity
    file_hash = calculate_file_hash(csv_path_v1)
    mlflow.log_param("file_hash_md5", file_hash)

    run_id_v1 = run.info.run_id
    print(f"✅ Dataset v1 logged successfully!")
    print(f"   Run ID: {run_id_v1}")
    print(f"   File Hash: {file_hash}")
```

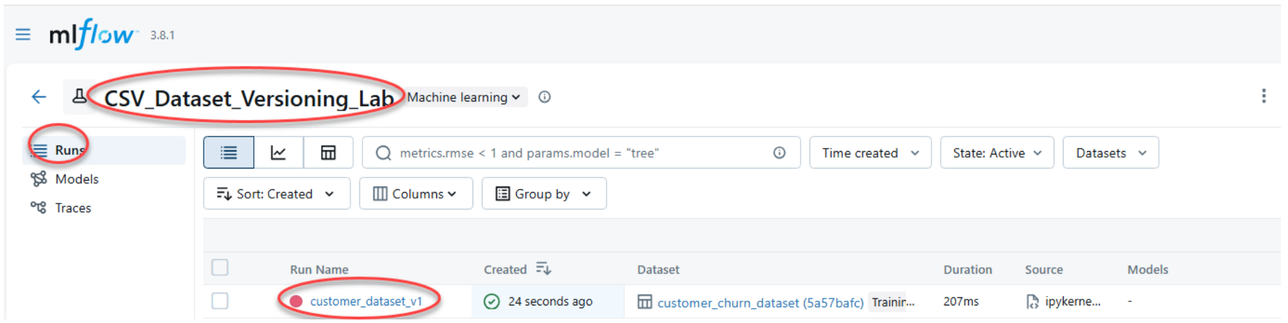

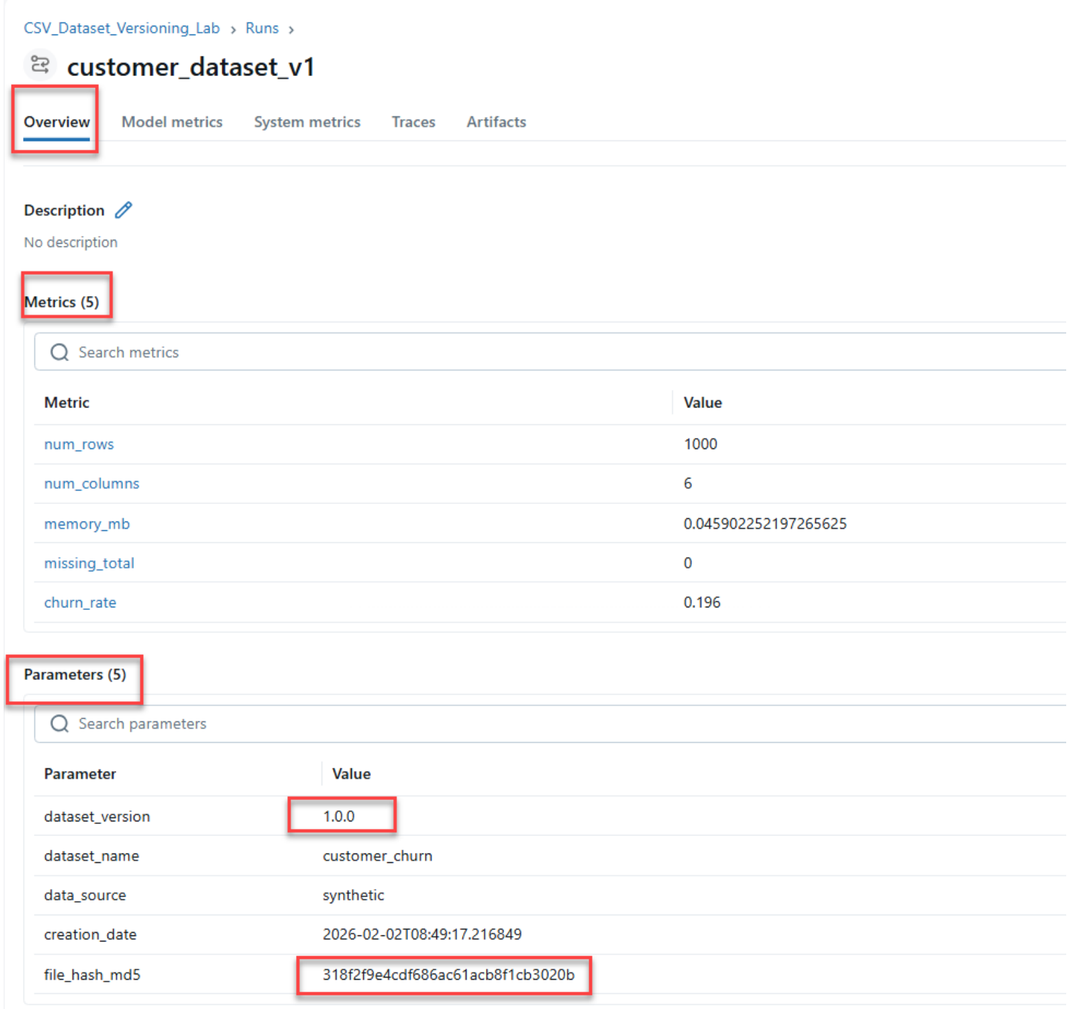

Version 1

```python
# Log CSV Dataset Version 1
print("🔄 Logging CSV Dataset Version 1...")

with mlflow.start_run(run_name="customer_dataset_v1") as run:
    # Load the dataset for MLflow
    df = pd.read_csv(csv_path_v1)

    # Create MLflow dataset
    dataset = mlflow.data.from_pandas(
        df,
        source=csv_path_v1,
        name="customer_churn_dataset",
        targets="churn"
    )

    # Log the dataset
    mlflow.log_input(dataset, context="training")

    # Log dataset metadata as parameters
    mlflow.log_param("dataset_version", "1.0.0")
    mlflow.log_param("dataset_name", "customer_churn")
    mlflow.log_param("data_source", "synthetic")
    mlflow.log_param("creation_date", datetime.now().isoformat())

    # Log dataset statistics as metrics
    stats = get_dataset_stats(df)
    mlflow.log_metric("num_rows", stats["num_rows"])
    mlflow.log_metric("num_columns", stats["num_columns"])
    mlflow.log_metric("memory_mb", stats["memory_usage_mb"])
    mlflow.log_metric("missing_total", sum(stats["missing_values"].values()))
    mlflow.log_metric("churn_rate", df['churn'].mean())

    # Log the actual CSV file as artifact
    mlflow.log_artifact(csv_path_v1, artifact_path="datasets")

    # Log schema information
    schema_info = {
        "columns": stats["columns"],
        "dtypes": stats["dtypes"],
        "version": "1.0.0"
    }
    schema_path = os.path.join(CSV_DIR, "schema_v1.json")
    with open(schema_path, 'w') as f:
        json.dump(schema_info, f, indent=2)
    mlflow.log_artifact(schema_path, artifact_path="schema")

    # Log file hash for integrity
    file_hash = calculate_file_hash(csv_path_v1)
    mlflow.log_param("file_hash_md5", file_hash)

    run_id_v1 = run.info.run_id
    print(f"✅ Dataset v1 logged successfully!")
    print(f"   Run ID: {run_id_v1}")
    print(f"   File Hash: {file_hash}")
```

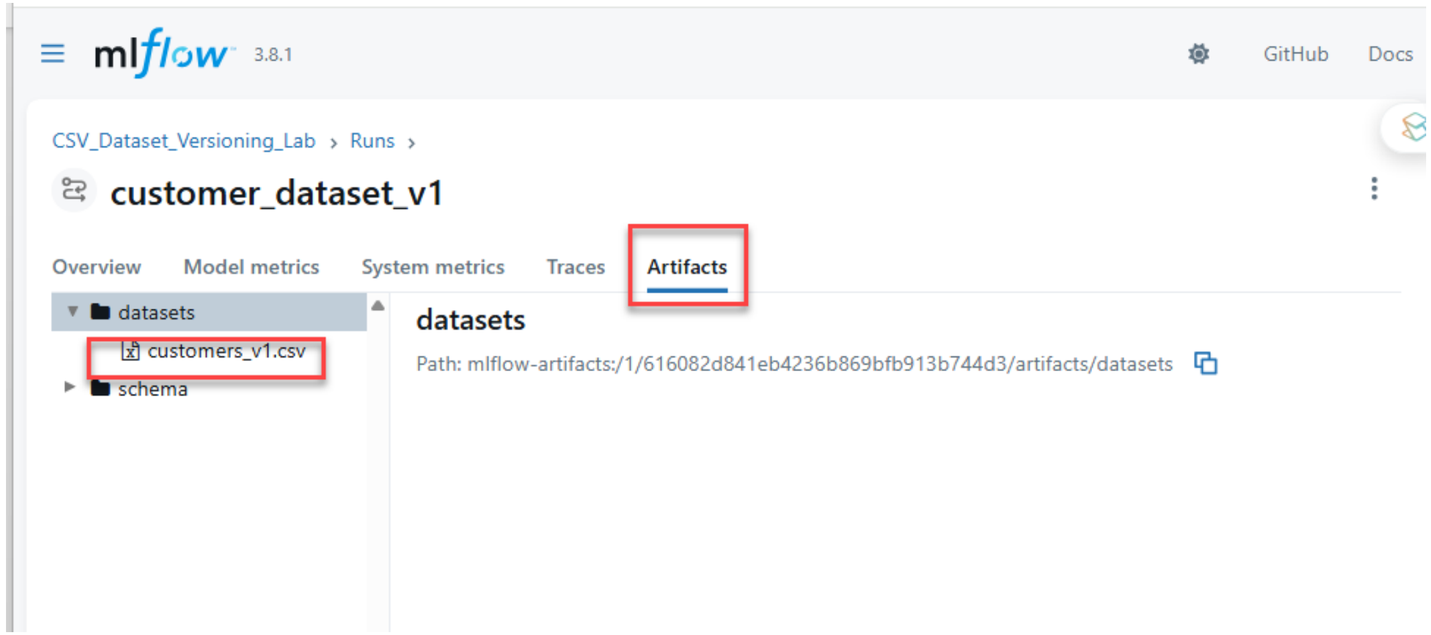

Version 2

```python
# Log CSV Dataset Version 2
print("🔄 Logging CSV Dataset Version 2...")

with mlflow.start_run(run_name="customer_dataset_v2") as run:
    # Load the dataset
    df = pd.read_csv(csv_path_v2)

    # Create MLflow dataset
    dataset = mlflow.data.from_pandas(
        df,
        source=csv_path_v2,
        name="customer_churn_dataset",
        targets="churn"
    )

    # Log the dataset
    mlflow.log_input(dataset, context="training")

    # Log dataset metadata
    mlflow.log_param("dataset_version", "2.0.0")
    mlflow.log_param("dataset_name", "customer_churn")
    mlflow.log_param("data_source", "synthetic")
    mlflow.log_param("creation_date", datetime.now().isoformat())
    mlflow.log_param("changes_from_v1", "Added region column, more samples")

    # Log statistics
    stats = get_dataset_stats(df)
    mlflow.log_metric("num_rows", stats["num_rows"])
    mlflow.log_metric("num_columns", stats["num_columns"])
    mlflow.log_metric("memory_mb", stats["memory_usage_mb"])
    mlflow.log_metric("missing_total", sum(stats["missing_values"].values()))
    mlflow.log_metric("churn_rate", df['churn'].mean())

    # Log artifact
    mlflow.log_artifact(csv_path_v2, artifact_path="datasets")

    # Log schema
    schema_info = {
        "columns": stats["columns"],
        "dtypes": stats["dtypes"],
        "version": "2.0.0"
    }
    schema_path = os.path.join(CSV_DIR, "schema_v2.json")
    with open(schema_path, 'w') as f:
        json.dump(schema_info, f, indent=2)
    mlflow.log_artifact(schema_path, artifact_path="schema")

    file_hash = calculate_file_hash(csv_path_v2)
    mlflow.log_param("file_hash_md5", file_hash)

    run_id_v2 = run.info.run_id
    print(f"✅ Dataset v2 logged successfully!")
    print(f"   Run ID: {run_id_v2}")
    print(f"   File Hash: {file_hash}")
```

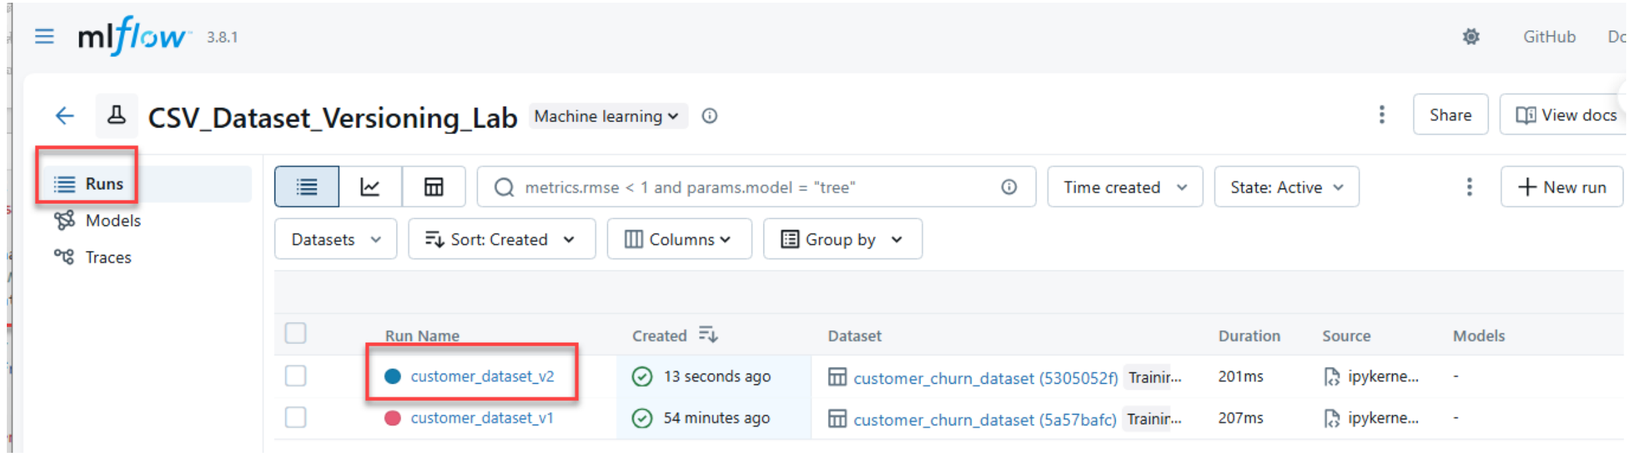

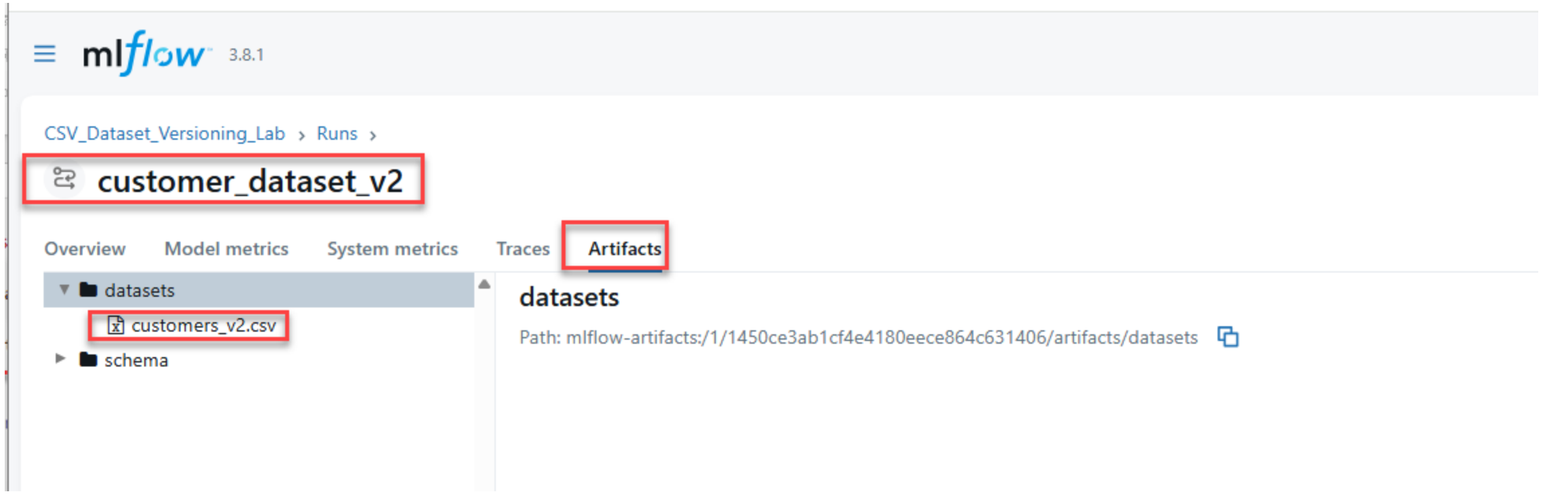

Compare CSV Dataset Versions

```
# Compare dataset versions
print("📊 Comparing Dataset Versions:")
print("=" * 60)

client = mlflow.tracking.MlflowClient()

# Get runs from the experiment
runs = client.search_runs(
    experiment_ids=[experiment.experiment_id],
    order_by=["start_time DESC"]
)

comparison_data = []
for run in runs:
    if "customer_dataset" in run.info.run_name:
        version_info = {
            "Run Name": run.info.run_name,
            "Version": run.data.params.get("dataset_version", "N/A"),
            "Rows": run.data.metrics.get("num_rows", "N/A"),
            "Columns": run.data.metrics.get("num_columns", "N/A"),
            "Churn Rate": f"{run.data.metrics.get('churn_rate', 0):.2%}",
            "Memory (MB)": f"{run.data.metrics.get('memory_mb', 0):.2f}"
        }
        comparison_data.append(version_info)

comparison_df = pd.DataFrame(comparison_data)
print(comparison_df.to_string(index=False))
```

```
📊 Comparing Dataset Versions:
============================================================
          Run Name Version   Rows  Columns Churn Rate Memory (MB)
customer_dataset_v2   2.0.0 1500.0      7.0     25.67%        0.15
customer_dataset_v1   1.0.0 1000.0      6.0     19.60%        0.05
```

Dataset Versioning for Images files